

AgentFlow: Plataforma de Analítica Visual Investigativa para Reconstruir la Filtración del Embargo de TenantThread (VAST Challenge 2026, MC-1)

Jyns Arturo Ordóñez Del Carpio

Universidad de Ingeniería y Tecnología (UTEC), Lima, Perú
jyns.ordonez@utec.edu.pe

Bihonda Epiro

Universidad de Ingeniería y Tecnología (UTEC), Lima, Perú
bihonda.epiro@utec.edu.pe

Cesar Pajuelo

Universidad de Ingeniería y Tecnología (UTEC), Lima, Perú
cesar.pajuelo@utec.edu.pe

ABSTRACT

El Mini-Challenge 1 del VAST Challenge 2026 pregunta cómo la información embargada de la fusión *Project HarborCrest* (TenantThread–CivicLoom) alcanzó la plataforma pública FleX ~35 minutos antes del levantamiento del embargo (18:00, 5 de junio de 2046), dado el registro de comunicaciones de siete agentes autónomos. Presentamos **AgentFlow**, una consola de investigación forense — deliberadamente no un dashboard — construida con D3.js v7 sobre un pipeline reproducible de ingeniería de atributos en Python. La investigación se condensa en dos vistas enlazadas: la *Trenza de Deriva Conductual*, que proyecta cada agente como un hilo sobre una escalera ordinal de postura encubierta-a-pública, compuesta con líneas base esperadas, arcos de coordinación encubierta, compuertas de cumplimiento, la cadena causal E01–E12 y un sismógrafo de indicadores tempranos con umbrales pre-crisis $\mu+1\sigma/\mu+2\sigma$; y la *Balanza de Hipótesis*, un modelo de evidencia transparente cuyas doce categorías, ponderadas con retornos decrecientes $w_c = b_c(1 - e^{-n_c/s_c})$, inclinan físicamente una balanza entre INTENCIONAL y FALLO SISTÉMICO. Toda señal es una fórmula aritmética documentada, auditable hasta el mensaje original desde un Inspector de Evidencia persistente. Sobre los 912 mensajes, la balanza se inclina 25.3 vs. 14.2 hacia una brecha con núcleo deliberado, ejecutada por los dos agentes que dominaban el canal encubierto y precedida por indicadores tempranos detectables desde el 22 de mayo.

Index Terms: Analítica visual, detección de anomalías conductuales, análisis forense de comunicaciones, ponderación de evidencia, VAST Challenge.

1 INTRODUCCIÓN

TenantThread negocia en secreto su adquisición por CivicLoom bajo un embargo hasta las 18:00 del 5 de junio de 2046. Siete agentes autónomos (legal, redes sociales, calidad, RR.PP., dos practicantes y un agente de cumplimiento, *The Judge*) intercambian 912 mensajes por seis canales de trazabilidad decreciente; el hecho embargado aparece 35 minutos antes. Ningún mensaje aislado constituye la brecha: la señal es un gradiente de coordinación encubierta, pruebas de límite y divulgación incremental vía lenguaje “defendible” de gobernanza, y la pregunta central (¿deliberada o sistémica?) es un juicio. Contribuciones: (1) un pipeline donde cada puntaje es una fórmula auditable; (2) la *Trenza de Deriva Conductual*, que vuelve la deriva geometría literal; (3) un *sismógrafo* con umbrales de alerta temprana estadísticamente fundados; (4) la *Balanza de Hipótesis*, ponderación explícita de evidencia que apoya — no reemplaza — el juicio del analista.

2 DATOS E INGENIERÍA DE ATRIBUTOS

Un script deriva siete datasets JSON (messages, rounds, network, actors, posts, events, meta). *Ningún puntaje es caja negra*. Cinco familias léxicas transparentes marcan el contenido público (nlp:

lo *dicho*) y el razonamiento privado (nlp_inner: lo *sabido*): **merger** (el sujeto embargado: civicloom, harborcrest), **embargo** (conciencia: 6 pm, confidential), **execution** (el acto: executing, going live), **compliance** (racionalización: 10b-5, defensible) y **governance** — el hallazgo del caso: la brecha se filtró mediante “aclaraciones de gobernanza” individualmente defendibles (audit, consent management), no con afirmaciones burdas. La sensibilidad por mensaje es

$$S(m) = 3.0|M_m| + 2.0|E_m| + 1.5|G_m| + 1.0|X_m| \quad (1)$$

sobre los conteos merger/embargo/governance/execution. La *violación de embargo* es la conjunción estricta $V(m) = (\text{público} \wedge \text{lenguaje merger} \wedge t_m < t_{\text{embargo}})$; 16 mensajes califican. Cada post público p recibe una verosimilitud de filtración

$$LL(p) = 0.45[|M_p| > 0] + 0.20[t_p < t_{\text{emb}}] + 0.15[|X_p| > 0] + 0.10[\text{anónimo}] + 0.10 \min(C(p), 10)/10, \quad (2)$$

donde el score de coordinación $C(p)$ cuenta los mensajes encubiertos en `side_huddle` de los 90 minutos previos — la firma de un acto *preparado*. La *betweenness* (Brandes) se computa **solo sobre aristas privadas/encubiertas**: el equipo es una clique de difusión y la métrica global es trivialmente cero; restringida, revela quién puentea las conversaciones reservadas (legal: 0.36, máximo). El *brokerage* $B(a) = (\text{mensajes encubiertos} + \text{privados}) \times (\text{posts públicos})$, normalizado, halla el conducto interno → público (redes sociales 1.00, legal 0.78). La desviación conductual es la distancia L_1 normalizada $D(a) = \frac{1}{2} \sum_c |\pi_a^{\text{crisis}}(c) - \pi_a^{\text{base}}(c)|$ entre las mezclas de canales de crisis y pre-crisis, más los `new_channels` nunca usados en la línea base.

3 DISEÑO VISUAL

Racional. La pantalla es un expediente forense: barra de filtros, lienzo central, *Inspector de Evidencia* persistente. Cualquier elemento carga sus mensajes con los términos resaltados y el razonamiento interno visible — de la abstracción visual a la prueba textual en un clic. Un único estado `filtered()` (actores, canales, banderas, ventana temporal, búsqueda) gobierna todas las vistas; los filtros tienen conmutadores todo/nada y Reset de un clic; la búsqueda dibuja un sparkline por ronda de menciones. El tiempo es ordinal por ronda para no aplastar las nueve horas decisivas. Interfaz bilingüe (EN/ES), tema claro/oscuro.

Trenza de Deriva Conductual. Cada agente es un hilo sobre una escalera ordinal de postura $\Pi = \{\text{huddle monitoreado} = 0, 1:1 = 1, \text{side-huddle} = 2, \text{oficial} = 3, \text{personal} = 4, \text{anónimo} = 5\}$; su posición por ronda es la media ponderada

$$y_a(r) = \frac{\sum_m w_m \Pi(c_m)}{\sum_m w_m}, \quad w_m = 3 \text{ si público, si no } 1, \quad (3)$$

de modo que la exposición jala visiblemente el hilo; cruzar el *perímetro rojo de aplicación* significa contenido público. Capas compuestas: líneas base puntuadas pre-crisis ($\mu \pm \sigma$ de y_a), arcos púrpura de coordinación encubierta, compuertas del Judge (verde = contuvo; rojo = siguió violación en $[r, r+2]$) con la franja autodetectada JUDGE SILENT, la cadena causal E01–E12 con flechas de decisión (incluida la roja “advertencia ignorada” E09→E10) y un triángulo por post público, con borde rojo si viola. Un panel de *Key Questions* reconfigura la trenza por tarea del reto con evidencia enlazada.

Sismógrafo. Cada ronda se puntúa

$$A(r) = 0.4\S_r + 1.0n_r^{\text{covert}} + 3.0n_r^{\text{boundary}} + 6.0n_r^{\text{viol}} \quad (4)$$

contra umbrales pre-crisis $\mu+1\sigma$ (alerta temprana) y $\mu+2\sigma$ (alarma), junto al precio \$TTHR y filas de marcas covert/boundary/violación por ronda.

4 LA BALANZA DE HIPÓTESIS

Cada categoría de evidencia es un *peso físico* que cae en el platillo rojo (INTENCIONAL) o azul (FALLO SISTÉMICO) de una balanza SVG animada por fuerzas. El peso efectivo de la categoría c con n_c mensajes satura:

$$w_c = b_c(1 - e^{-n_c/s_c}), \quad (5)$$

así el primer acierto cuenta máximo y *el volumen no ahoga la señal*: una violación atribuible en canal oficial ($b=8$) pesa más que docenas de menciones de gobernanza ($b=2$). La Tabla 1 lista las doce categorías con sus reglas exactas — mostradas en la interfaz como tooltips de transparencia (por qué importa, regla, b_c , n_c , polo); el clic carga sus mensajes. El término estructural de concentración codifica que las brechas concentradas indican diseño: $w_{\text{conc}} = 6.5 \cdot \sum_{a \in \text{top-2}} v_a / \sum_a v_a$ sobre las violaciones v_a por agente. Las categorías mapean con multiplicadores con signo a las tres hipótesis (A deliberada, B fallo de coordinación, C emergente con núcleo deliberado); $\text{net}_h = \max(0, \Sigma\text{FOR} - \Sigma\text{AGAINST})$, $\text{conf}_h = \text{net}_h / \Sigma\text{net}$, cerrando como CONFIRMADA con $\geq 45\%$ y ventaja ≥ 12 puntos o RECHAZADA con $\leq 15\%$. La inclinación $\theta = 0.26 \tanh((W_{\text{sys}} - W_{\text{int}})/7)$ mantiene legibles los desbalances extremos; un banner de veredicto la reformula en lenguaje llano bajo cada filtro. La balanza muestra el *balance de la evidencia*, nunca una conclusión de la máquina.

5 RESPUESTAS A LAS TAREAS DEL MC-1

P1 — Eventos, relaciones, decisiones. La cadena se lee en la trenza: el CEO siembra “strategic developments” en privado (17 mayo, E01) → se activa el canal encubierto *side_huddle* y allí se hace el briefing (22 mayo, E02–E03) → el Judge se asigna recién tras un faux pas público (30 mayo, E04) → presión de los exposés SaltWind (31 mayo/4 junio, E05–E06) → 5 de junio: post anónimo referencia el acuerdo (09:49, E07), escalan las pruebas de límite (E08), la advertencia de las 15:08 (E09) es ignorada → Legal publica en su cuenta personal a las 17:25 (E10), Redes Sociales amplifica (E11), brecha confirmada antes de las 18:00 (E12). Decisiones clave: activar el canal encubierto, llevar el briefing allí, ignorar E09, publicar.

P2 — Qué dejó pasar el post. (1) Control tardío: las compuertas aparecen recién el 30 de mayo, con la coordinación ya encubierta; (2) el hueco silencioso: cero salida de cumplimiento en la mañana crítica, cuando ocurren las primeras violaciones; (3) poder solo consultivo: E09 es dictamen, no bloqueo; (4) alcance: el control vigilaba la cuenta oficial mientras la brecha viajaba por canales personal/anónimo — exactamente donde terminan el día los hilos de Legal y Redes Sociales.

P3 — Típico vs. brecha. Dos semanas pre-crisis de hilos planos en zonas monitoreadas definen la normalidad; el 5 de junio el hilo de Legal se hunde a través del perímetro: $D = 0.31$, 176 mensajes

Table 1: Categorías de evidencia: peso base, saturación, regla.

Categoría	b_c	s_c	Regla de asignación
<i>Polo INTENCIONAL</i>			
Filtración atribuible	8	2	público $\wedge$ violación $\wedge$ canal oficial
Pre-siembra anónima	5	2	anónimo $\wedge$ merger $\wedge$ antes del embargo
Coordinación encubierta	4	20	merger/embargo en <i>side_huddle</i>
Concentración de brecha	$6.5 \times$	—	proporción del top-2 de agentes
Clúster temporal	6	1	violación $\wedge$ ronda de crisis
Escalada de canal	5	1	mismo agente viola vía covert y personal/anónimo
<i>Polo FALLO SISTÉMICO</i>			
Prueba de límite	3	8	público $\wedge$ merger/embargo $\wedge$ $\neg$ violación
Filtración sin control	4	6	violación $\wedge$ canal no oficial
Aclaración defensiva	2	3	público $\wedge$ compliance $\wedge$ $\neg$ violación
Control tardío	3	fijo	Judge desplegado ~ 1 semana antes (E04)
Advertencia no aplicada	1.5	fijo	E09 emitida sin poder coercitivo
Refuerzo entre canales	3	—	merger activo en los 3 canales públicos a la vez

vs. línea base de 90, 12 posts anónimos y *dos canales públicos nunca antes usados*. Redes Sociales replica el descenso; los demás agentes quedan en su línea base, aislando la anomalía en el mismo par que domina el brokerage.

P4 — Indicadores tempranos. Sí: el sismógrafo supera $\mu+1\sigma$ el 22 de mayo (activación encubierta) y el 29 de mayo (casi-incidente público) y cruza $\mu+2\sigma$ horas antes de la brecha; la pre-siembra anónima empieza a las 09:49, ocho horas antes de la confirmación.

P5 — Desviaciones previas. 22 de mayo: agentes sénior sacan la conversación del canal monitoreado (primera caída de postura, primeros arcos púrpura). 29 de mayo: el post de @Elena roza el lenguaje de la fusión — el faux pas que motivó asignar al Judge. 31 mayo–4 junio: crecen las aclaraciones con marco de gobernanza — defendibles en local, divulgadoras en conjunto.

P6 — Episodios similares. El patrón (alineación encubierta → prueba de límite pública) se ensaya dos veces: 22–23 de mayo (clúster encubierto + post adyacente a la fusión) y 29–30 de mayo (casi-incidente + aclaraciones defensivas); acotando la ventana a mayo, ambos son visualmente isomorfos al 5 de junio.

P7 — Por qué no hubo acción. Las compuertas verdes se leyeron como éxito (confianza falsa); cada prueba de límite era defendible en sí misma, así que las alertas por reglas nunca dispararon; el único escalamiento era consultivo. El sistema era ciego al *gradiente* — lo que el puntaje compuesto hace visible.

Veredicto. La balanza inclina INTENCIONAL 25.3 vs. 14.2: *comportamiento emergente con núcleo deliberado* — canales no monitoreados y controles tardíos habilitaron la filtración; un acto deliberado y atribuible la completó.

6 CONCLUSIÓN

Tres decisiones fueron determinantes: la escalera ordinal de postura ($\times 3$ público), la betweenness restringida a aristas privadas y la saturación exponencial de la evidencia. Los pesos base son editoriales (visibles, no aprendidos) y el veredicto es sensible al filtro por diseño. AgentFlow no decide por el analista; hace que su juicio sea *defendible*.