

AgentFlow: Visualización de Deriva Conductual y Ponderación de Evidencia en la Filtración del Embargo de TenantThread (VAST Challenge 2026, MC-1)

Jyns Arturo Ordóñez Del Carpio
Universidad de Ingeniería y Tecnología (UTEC), Lima, Perú
jyns.ordonez@utec.edu.pe

Bihonda Epiro
Universidad de Ingeniería y Tecnología (UTEC), Lima, Perú
bihonda.epiro@utec.edu.pe

Cesar Pajuelo
Universidad de Ingeniería y Tecnología (UTEC), Lima, Perú
cesar.pajuelo@utec.edu.pe




Figure 1:

ABSTRACT

El Mini-Challenge 1 del VAST Challenge 2026 pregunta cómo la información embargada de la fusión *Project HarborCrest* alcanzó la plataforma pública FleX ~35 minutos antes del levantamiento del embargo (18:00, 5 de junio de 2046), dado el registro de comunicaciones de siete agentes autónomos. Presentamos **AgentFlow**, una consola de investigación forense — deliberadamente no un dashboard — construida con D3.js v7 sobre un pipeline reproducible de ingeniería de atributos en Python. Dos vistas enlazadas condensan la investigación: la *Trenza de Deriva Conductual* (Fig. 1), que vuelve la deriva conductual geometría literal, y la *Balanza de Hipótesis* (Fig. 2), un modelo de evidencia transparente cuyas doce categorías inclinan físicamente una balanza entre INTENCIONAL y FALLO SISTÉMICO. Toda señal es una fórmula documentada y auditable. Sobre los 912 mensajes la balanza se inclina 25.3 vs. 14.2 hacia una brecha con núcleo deliberado, ejecutada por los dos agentes que dominaban el canal encubierto y precedida por indicadores tempranos detectables desde el 22 de mayo.

Index Terms: Analítica visual, detección de anomalías conductuales, análisis forense de comunicaciones, ponderación de evidencia, VAST Challenge.

1 INTRODUCCIÓN

TenantThread negocia en secreto su adquisición por CivicLoom bajo un embargo hasta las 18:00 del 5 de junio de 2046. Siete agentes autónomos (legal, redes sociales, calidad, RR.PP., dos prac-

ticantes y un agente de cumplimiento, *The Judge*) intercambian 912 mensajes por seis canales de trazabilidad decreciente; el hecho embargado aparece 35 minutos antes. Ningún mensaje aislado constituye la brecha: la señal es un gradiente distribuido de coordinación encubierta, pruebas de límite y divulgación incremental vía lenguaje “defendible” de gobernanza. AgentFlow es por ello una *consola de investigación*: un único estado global de filtrado (actores, canales, banderas, ventana temporal, búsqueda) gobierna todas las vistas, y cualquier elemento visual carga sus mensajes en un Inspector de Evidencia persistente, separando lo *dicho* de lo *sabido*.

2 DESCRIPCIÓN DEL SISTEMA

Procesamiento de datos. Un único script en Python deriva todos los atributos. Cinco familias léxicas transparentes (merger, embargo, execution, compliance, governance) marcan el contenido público y el razonamiento privado; la sensibilidad por mensaje las pondera por gravedad legal (merger $\times 3$, embargo $\times 2$, governance $\times 1.5$, execution $\times 1$). La *violación de embargo* es la conjunción estricta de canal público, lenguaje merger y publicación antes de las 18:00 — 16 mensajes califican. Cada post público recibe además una *verosimilitud de filtración* dominada por el lenguaje merger, el timing pre-embargo y un *score de coordinación* que cuenta los mensajes encubiertos en *side_huddle* de los 90 minutos previos; como verificación de sanidad, sus posts top son exactamente el clúster real de la brecha (17:25–17:54). En el grafo de agentes, la betweenness se computa solo sobre aristas privadas/encubiertas (el




Figure 2: La *Balanza de Hipótesis*: doce categorías de evidencia auditables caen como pesos en el platillo INTENCIONAL (rojo) o FALLO SISTÉMICO (azul); el libro mayor (derecha) muestra el peso efectivo de cada categoría y el polo que impulsa, con el método completo expuesto. Sobre los 912 mensajes la balanza se inclina 25.3 vs. 14.2 hacia INTENCIONAL.

equipo difunde a todos, la métrica global degenera), y el *brokerage* — mensajes encubiertos enviados $\times$ posts públicos — identifica el conducto interno $\rightarrow$ público. La desviación conductual compara la mezcla de canales del día de crisis contra la línea base pre-crisis (distancia L_1), más los canales públicos nunca antes usados.

Trenza de Deriva Conductual (Fig. 1). La posición de cada agente por ronda es su promedio de canales con los mensajes públicos ponderados $\times 3$, de modo que la exposición jala visiblemente el hilo. Bajo la trenza, un *sismógrafo* puntúa cada ronda combinando sensibilidad léxica, mensajes encubiertos, pruebas de límite y violaciones con pesos crecientes según gravedad legal, contra umbrales de alerta temprana ($\mu + 1\sigma$) y alarma ($\mu + 2\sigma$) calculados sobre las rondas pre-crisis — el único lugar donde el dato, no el analista, fija el umbral. Un panel flotante de *Key Questions* reconfigura la trenza por tarea del reto con evidencia enlazada.

Balanza de Hipótesis (Fig. 2). Cada categoría de evidencia es un peso físico que cae en el platillo rojo (INTENCIONAL) o azul (FALLO SISTÉMICO). El peso efectivo satura como $w_c = b_c(1 - e^{-n_c/s_c})$: el primer acierto cuenta máximo y los siguientes saturan, así *el volumen no ahoga la señal* — una violación atribuible en canal oficial (base 8) pesa más que docenas de menciones rutinarias de gobernanza (base 2). Los pesos base codifican fuerza probatoria relativa; las saturaciones siguen la frecuencia esperada (lo raro y concluyente satura en 1–2 casos; los mensajes encubiertos, individualmente débiles, necesitan 20). Cada categoría expone en un tooltip su regla de asignación, peso, conteo y polo; el clic carga sus mensajes, y un banner de veredicto reformula la inclinación bajo cada filtro.

3 RESPUESTAS A LAS TAREAS DEL MC-1

P1 — Eventos, relaciones, decisiones. La cadena se lee en la trenza: el CEO siembra “strategic developments” en privado (17 mayo, E01) $\rightarrow$ se activa el canal encubierto *side_huddle* y allí se hace el briefing (22 mayo, E02–E03) $\rightarrow$ el Judge se asigna recién tras un faux pas público (30 mayo, E04) $\rightarrow$ presión de los exposés SaltWind (E05–E06) $\rightarrow$ 5 de junio: un post anónimo referencia el acuerdo (09:49, E07), escalan las pruebas de límite (E08), la advertencia de las 15:08 (E09) es ignorada $\rightarrow$ Legal publica en su cuenta personal a las 17:25 (E10), Redes Sociales amplifica (E11), brecha confirmada antes de las 18:00 (E12). Decisiones clave: activar el canal encubierto, llevar el briefing allí, ignorar E09, publicar.

P2 — Qué dejó pasar el post. (1) Control tardío: las compuertas aparecen recién el 30 de mayo, con la coordinación ya encu-

bierta; (2) el hueco silencioso: cero salida de cumplimiento en la mañana crítica, cuando ocurren las primeras violaciones; (3) poder solo consultivo: E09 es dictamen, no bloqueo; (4) alcance: el control vigilaba la cuenta oficial mientras la brecha viajaba por canales personal/anónimo — donde terminan el día los hilos de Legal y Redes Sociales.

P3 — Típico vs. brecha. Dos semanas pre-crisis de hilos planos en zonas monitoreadas definen la normalidad; el 5 de junio el hilo de Legal se hunde a través del perímetro: desviación 0.31, 176 mensajes vs. línea base de 90, 12 posts anónimos y *dos canales públicos nunca antes usados*. Redes Sociales replica el descenso; los demás agentes quedan en su línea base, aislando la anomalía en el mismo par que domina el brokerage.

P4 — Indicadores tempranos. Sí: el sismógrafo supera $\mu + 1\sigma$ el 22 de mayo (activación encubierta) y el 29 de mayo (casi-incidente público) y cruza $\mu + 2\sigma$ horas antes de la brecha; la pre-siembrá anónima empieza a las 09:49, ocho horas antes.

P5 — Desviaciones previas. 22 de mayo: agentes sénior sacan la conversación del canal monitoreado (primera caída de postura, primeros arcos púrpura). 29 de mayo: el post de @Elena roza el lenguaje de la fusión — el faux pas que motivó asignar al Judge. 31 mayo–4 junio: crecen las aclaraciones con marco de gobernanza — defendibles en local, divulgadoras en conjunto.

P6 — Episodios similares. El patrón (alineación encubierta $\rightarrow$ prueba de límite pública) se ensaya dos veces: 22–23 de mayo (clúster encubierto + post adyacente a la fusión) y 29–30 de mayo (casi-incidente + aclaraciones defensivas); acotando la ventana a mayo, ambos son isomorfos al 5 de junio.

P7 — Por qué no hubo acción. Las compuertas verdes se leyeron como éxito (confianza falsa); cada prueba de límite era defendible en sí misma, así que las alertas por reglas nunca dispararon; el único escalamiento era consultivo. El sistema era ciego al *gradiente* — lo que el puntaje compuesto hace visible.

Veredicto. La balanza inclina INTENCIONAL 25.3 vs. 14.2: *comportamiento emergente con núcleo deliberado* — canales no monitoreados y controles tardíos habilitaron la filtración; un acto deliberado y atribuible la completó.

4 CONCLUSIÓN

Tres decisiones fueron determinantes: la escalera ordinal de postura ($\times 3$ público), la betweenness restringida a aristas privadas y la saturación exponencial de la evidencia. Los pesos base son editoriales y el veredicto sensible al filtro por diseño: AgentFlow no decide por el analista — hace su juicio *defendible*.